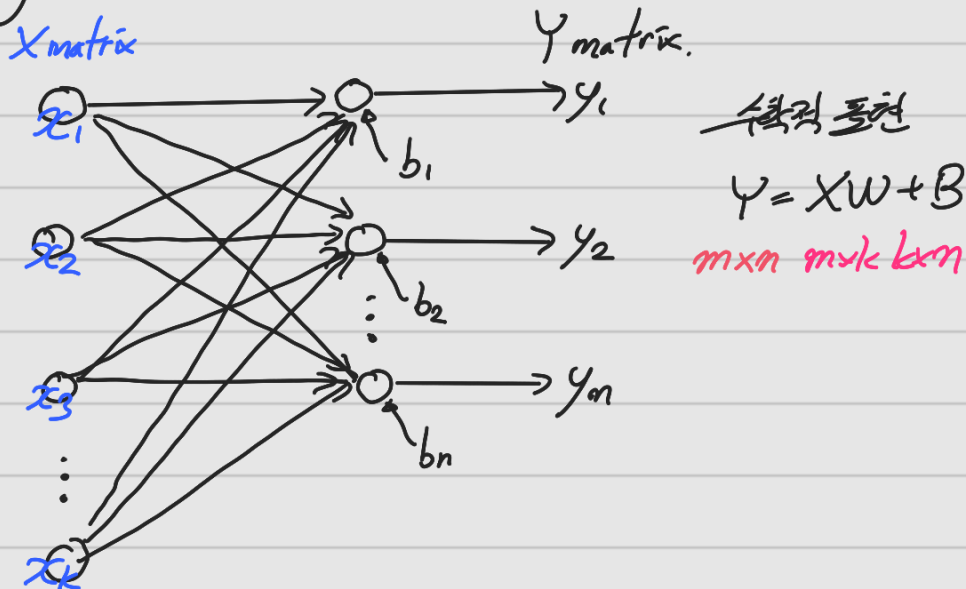


# Deep Learning 수학적 증명

## 1. SLP의 경우

a) Regression의 수학적 증명의 과정 수학적 증명



(수식화)

$$Y = XW + B \quad y_{ij} = x_{i1}w_{1j} + x_{i2}w_{2j} + \dots + x_{ik}w_{kj} + b_j$$

$$L = \frac{1}{m \cdot n} \sum_{i=1}^m \sum_{j=1}^n (\text{label}_{ij} - y_{ij})^2$$

given answer.      predicted value

일반적인 수식

(여기서)

$L$  is function of  $y_{11}, y_{12}, \dots, y_{mn}$ .

$$L = f(y_{11}, y_{12}, \dots, y_{mn})$$

$$\frac{\partial L}{\partial w_{ij}} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial w_{ij}}$$

$w_{ij}$ 가 영향을 주는 모든  $y$ 값들은 고려한다.

$y_{1j}, y_{2j}, \dots, y_{mj}$  총  $m$ 개의  $y$ 값.

$$= \frac{\partial L}{\partial y_{1j}} \cdot \frac{\partial y_{1j}}{\partial w_{ij}} + \frac{\partial L}{\partial y_{2j}} \cdot \frac{\partial y_{2j}}{\partial w_{ij}} + \dots + \frac{\partial L}{\partial y_{mj}} \cdot \frac{\partial y_{mj}}{\partial w_{ij}}$$

$$\frac{\partial L}{\partial y_{ij}} = \frac{1}{mn} \cdot 2(\text{label}_{ij} - y_{ij}) \cdot (-1)$$

$$\frac{\partial y_{xj}}{\partial w_{ij}} = \underline{x_{xi}}$$

$\frac{\partial L}{\partial w}$  = this is the matrix to updating weight matrix  $W$  ( $k \times n$ )

$$= \begin{bmatrix} x^T \cdot \left( \frac{\partial y}{\partial w} \right) \\ \hline x_{1i} \ x_{2i} \ x_{3i} \ \dots \ x_{ni} \\ \hline \vdots \\ \hline \end{bmatrix} \begin{bmatrix} \left( \frac{\partial y}{\partial y} \right) \text{diff}_{1j} \\ \text{diff}_{2j} \\ \text{diff}_{3j} \ \dots \\ \vdots \\ \text{diff}_{nj} \end{bmatrix} \cdot \frac{1}{mn} \cdot (-2)$$


and the component  $\frac{\partial y}{\partial w_{ij}} = \frac{1}{mn} [2(\text{label}_{ij} - y_{ij}) \cdot (-1) \cdot x_{1i} + 2(\text{label}_{2j} - y_{2j}) \cdot (-1) \cdot x_{2i}$

so  $\frac{\partial L}{\partial w} = (-2 \times \frac{1}{mn}) \cdot \underbrace{x^T}_{(k \times n)} \cdot \underbrace{(\text{label matrix} - y \text{ matrix})}_{\equiv \text{Diff matrix } (m \times n)} \quad k \times n \text{ matrix.}$

## b) Binary Classification - 수식적 증명

여러 Binary Classification을 위해 2가지 개념을 새로이 도입한다.

1. Sigmoid Function  $\rightarrow$  logit value를 0과 1의 확률의 차가 되는 비선형 함수  
(result of NN)



2. Cross-Entropy (크로스 엔트로피); 두 확률값  $P, Q$ 가 주어질 때, 두 확률값이 얼마나 다른지를 나타내는 수치를 표현하기 위한 개념이다.

$$H(P, Q) = \sum_{i=1}^m P_i \log \frac{1}{Q_i} = \sum_{i=1}^m -P_i \log Q_i$$

이 크로스 엔트로피는 두 확률값이 얼마나 다른지를 나타내는 수치를 표현한다.

Binary Classification에서  $P_i$ 의 의미:

모범답안으로 주어지는 label의 정답은 입력에 따른 조건부 확률로서

$P$ 를 재해석하고, 이를 이용하여 cross entropy를 계산하는 방식을 통해, 문제를 해결한다.

ex)  $P_i$ : label data.  $Q_i$ : predicted probability.

at given input data ( $X_i$ )

$\langle X_{i1}, X_{i2}, \dots, X_{ik} \rangle$  this is a condition

and  $g_i$  is predicted probability when  $X_i$ 's condition is given.

label data  $P_i$ 는 0 혹은 1로 주어진다.

이  $P_i$ 는 조건부 확률 ( $X_i$ )에 대한 확률이다.

$H(P, Q)$ 를 줄이는 방식으로 학습을 진행한다면, 줄이는 pattern이

$\equiv$  다양한 입력형 상에 대한 교차 Entropy를

줄이는 방향으로 학습을 진행한다.

실정성이 반영되어 각각의 입력에 알맞는 조건부 확률분포를

$\equiv$  각각의 입력에 알맞는 단말은 점도를 투로.

적합히 만들어낼 수 있을 것이다.